

Filtrage Collaboratif

Mohamed EL KHMISSE
Mohamed Abdelmalek BOUARROUDJ
Rapport de projet d'Apprentissage Statistique
2022/2023

1 Introduction

De nos jours tous les géants mondiaux de la tech mettent en place des systèmes de recommandation pour déterminer les produits les plus susceptibles d'intéresser les clients à partir d'un certain nombre d'informations, c'est ce qu'on appelle filtrage collaboratif. les systèmes les plus utilisés sont basés sur la recherche de quelques facteurs latents susceptibles d'expliquer en faible dimension les interactions entre clients et produits.

Dans ce rapport nous allons essayer de prédire les notes qu'un lecteur pourrait donner à un livre qui n'a pas lu encore par la méthode de filtrage collaboratif appeler NMF (factorisation matricielle non négative).

2 Présentation des données

Tout d'abord BookCrossing est un site de réseau social intelligent qui met les gens en contact par les livres, le but est de faire passer un livre d'un lecteur à un autre sans frontière.

Nous avons récolté notre base de données "Book-Crossing Dataset" de ce site,¹ elle comprend 278.860 BookCrosseurs (lecteurs) et 271.360 livres, et on dispose pour chaque lecteur les évaluations qu'il a donné à des livres lus (plus que 1.149.781 évaluations entre 1 le pire et 10 le meilleur).

Pour notre cas pratique nous avons pris tous les livres qui ont été noté par au moins 100 lecteurs et tous les lecteurs qui ont notés au moins 300 livres soit au total 553 lecteurs et 731 livres.

User-ID	ISBN	Book-Rating	Book-Title	Book-Author
0	276725 034545104X	0	Flesh Tones: A Novel	M. J. Rose
1	276726 0155061224	5	Rites of Passage	Judith Rae
2	276727 0446520802	0	The Notebook	Nicholas Sparks
3	276729 052165615X	3	Help!: Level 1	Philip Prowse
4	276729 0521795028	6	The Amsterdam Connection : Level 4 (Cambridge ...	Sue Leather

FIGURE 1 – Extrait de la base de données

A partir de cette base de données nous avons créés une matrice $X \in \mathbb{R}^{n \times p}$, contenant pour chaque lecteur i (ligne) une note d'appréciation de 1 à 10 d'un livre j (colonne), la matrice X est donc très creuse et contient que des valeurs non négatives.

$$X = \begin{pmatrix} 8 & 0 & \dots & 0 & 1 \\ 1 & 3 & \dots & 6 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \dots & 0 & 0 \\ 0 & 0 & \dots & 0 & 5 \end{pmatrix}_{n \times p}$$

Remarque la valeur "0" signifie une donnée manquante (le livre n'a pas encore été lu ou évalué), c'est d'ailleurs la valeur qu'on veut prédire pour recommander au lecteur (i) le livre (j) si la note prédite dépasse un certain seuil.

3 Principe de la Factorisation Matricielle Non-Négative

L'idée principale derrière un problème de factorisation matricielle non-négative est d'apprendre un modèle latent de lecteurs $W \in \mathbb{R}^{n \times r}$ et de livres $H \in \mathbb{R}^{r \times p}$ de sorte que la reconstruction $\hat{X}_{ij} = W_i H_j$ entre un lecteur i et un livre j estime la note X_{ij} . Autrement dit la recherche de deux

ne pouvons pas les décrire, ça serait plutôt f_1 et f_2).

Les coordonnées de la matrice W représentent l'appétence qu'un lecteur a pour le type de livre k , et les coordonnées de la matrice H représentent le poids du facteur k pour un livre donné.

Le lecteur E il a une appétence de 3 pour les livres de romance et 1 pour les livres d'histoire, et le livre $L1$ a un poids de 3 pour les livres de romance et 1 pour les livres d'histoire, en faisant le produit des facteurs latents du lecteur E et le livre $L1$ nous retrouvons la note que ce lecteur est susceptible de donner à ce livre.

6 Cas pratique

Pour répondre à notre problématique qui est de prédire les notes qu'un lecteur pourrait donner à un livre nous allons utiliser la méthode NMF de la librairie `sckit-learn` qui se base sur la résolution du problème que nous avons présentés dans la section 4.

Nous avons pris les paramètres suivants :

- La méthode "mu" (Multiplicative Update solver) pour la factorisation de la matrice X en WH .
- $l1_ratio = 1$ et donc pénalité L1 ce qui va forcer certaines valeurs de H et W à être égale à 0.
- Rang de factorisation $r = (8, 9, 10, 11, 12, 13, 14)$
- $\alpha = \alpha_W = \alpha_H = (0, 0.025, 0.05, 0.075, 0.1)$

Nous avons pris la matrice X de taille (553, 731) qui contient 404.243 coordonnées dont a peu près 9.000 valeurs remplis et 395.243 valeurs manquantes que nous allons essayer de prédire.

Pour calibrer le meilleur couple de paramètre (r, α) nous allons procéder comme suit :

- Prendre un couple (r, α)
- Prendre 100 coordonnées non nulles de la matrice X les vider puis calculer \hat{X}
- Calculer le RMSE entre X et \hat{X} (pour les 100 coordonnées dont on connaît les vraies valeurs)

- Répéter le procédure 20 fois
- Calculer l'erreur le RMSE moyen de chaque couple (r, α) puis prendre l'optimal.

À la fin, nous avons créé une fonction qui, à partir d'un seuil donné elle renvoie les titres des livres à recommander à des groupes de lecteurs. (voir le script pour plus détails²)

Références

¹ <http://www2.informatik.uni-freiburg.de/cziegler/BX/>

² <https://github.com/ELKHMISSI/NMF>